


# PRML6章

担当：大木

# 導入

**3,4章では回帰・分類問題に  
対する線形手法を扱った**




**問：次のデータを二値分類せよ**



**線形識別では無理そう**

# 特徴選択

## 特徴変換



変換後は平面で分離できそう（線形識別可能）

## アイデア

元のデータ空間を特徴空間に非線形写像して、  
これまでの線形手法を適用！

# しかし...

- 適切な特徴変換を見つけるのは大変
- 特徴空間はデータ次元に対して非常に高次元で、計算資源的に厳しい

cf. 200次元データに対して3次のモーメントを考慮する場合

$$200C_1 + 200C_2 + 200C_3 = 1333500$$

## カーネル法

データの非線形性や高次モーメントを  
計算コストを抑えつつ、特徴変換を陽に決めずに  
上手く取り入れる手法

# カーネル法がうまくいく理由 →カーネルトリック

特徴変換関数を  $\Phi(x)$  とすると、  
特徴空間における内積(類似度)

$$\langle \Phi(X_i), \Phi(X_j) \rangle = k(X_i, X_j)$$

の値が得られれば変換関数の具体形が  
わからなくても線形データ解析が行える



さらに...

カーネル関数が実数なら入力データ  $X_i$  は  
複素数や文字列、グラフ構造などでも  
良い

→パターン認識での様々な応用

例：自然言語処理、バイオインフォマティクス...

# ここから本題

教科書(PRML)をベースに  
適宜補足しながら進めていきます

# 目次

6.1 双対表現

6.2 カーネル関数の構成

6.3 RBFネットワーク

6.4 ガウス過程

# 目次

## 6.1 双対表現


## 6.2 カーネル関数の構成

## 6.3 RBFネットワーク

## 6.4 ガウス過程

# 双対表現

回帰・分類に用いられる線形モデルの多くは、  
双対表現によってカーネル関数で書き直すことが可能



ということで、3章、4章でそれぞれ扱った  
リッジ回帰とフィッシャー判別分析について  
見ていく

# カーネルリッジ回帰

学習データセット

$(\mathbf{x}_1, t_1), \dots, (\mathbf{x}_N, t_N)$

$\mathbf{x}_n$ : 多次元説明変数

$t_n$ : 1次元目的変数

以下を最小化することを考える ( $\lambda \geq 0$ )

$$J(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\|^2 + \lambda \|\mathbf{w}\|^2$$

...(6.2)

極値を求めると

$$\mathbf{w} = -\frac{1}{\lambda} \sum_{n=1}^N \{\mathbf{w}^T \phi(\mathbf{x}_n) - t_n\} \phi(\mathbf{x}_n)$$

$$a_n = -\frac{1}{\lambda} \{ \mathbf{w}^T \phi(\mathbf{x}_n) - t_n \} \quad \text{とおくと}$$

$$\mathbf{w} = \sum_{n=1}^N a_n \phi(\mathbf{x}_n) \quad \text{という双対表現が得られる}$$

これを用いて、目的関数をaによって  
書き直すと(6.5)のようになる

式長いので参照にて勘弁してください

さらに、(6.1)のカーネル関数を行列要素に持つ

$$\text{グラム行列} \quad \mathbf{K} = \Phi \Phi^T$$

を用いて書き直すと、(6.7)のようになる

また、(6.3)を用いて(6.4)から $w$ を消去して  
 $a$ について解くと

$$\mathbf{a} = (\mathbf{K} - \lambda \mathbf{I}_N)^{-1} \mathbf{t} \quad (6.8)$$

これを線形モデルに代入しなおせば、  
新たなデータ $\mathbf{x}$ に対する予測は

$$y(\mathbf{x}) = \mathbf{k}(\mathbf{x})^T (\mathbf{K} - \lambda \mathbf{I}_N)^{-1} \mathbf{t} \quad (6.9)$$

以上から、リッジ回帰の最適解は  
カーネル関数のみで表現できることが確認できた



双対表現によってM次元パラメータベクトルwから、  
N次元パラメータベクトルaへ表記しなおすことができた

計算量は？

$M \times M$  vs.  $N \times N$

カーネル法の特長

特徴ベクトルを陽に扱わずに  
高次元の特徴空間を考えることが出来る

**おまけ:カーネルフィッシャー判別分析**

## フィッシャー判別分析(4.1.4～参照)

2クラス分類において、判別分析には  
以下の最大化問題を解けばよかった

$$\max \mathbf{w}^T \mathbf{S}_B \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \mathbf{S}_W \mathbf{w} = 1$$

非線形化するために、1次元射影関数を  
特徴空間上のものとする

$$y = \mathbf{w}^T \mathbf{x} \quad \Rightarrow \quad y = \mathbf{w}^T \phi(\mathbf{x})$$

ここで、特徴ベクトルの張る部分空間に直交するベクトルは目的関数の値に寄与しないので最適解は

$$\mathbf{w} = \sum_{n=1}^N a_n \phi(\mathbf{x}_n)$$

→リプレゼンター定理できちんとやります

と書ける

これを用いてクラス内分散の和とクラス間分散をカーネル関数で書き直すと

※途中の計算はスライドから省きます

クラス間分散

$$\mathbf{a}^T \mathbf{S}_B^\phi \mathbf{a}$$

$$\mu_i = \sum_{n \in C_i} \mathbf{k}(X_n, X)$$

$$\mathbf{S}_B^\phi = (\mu_2 - \mu_1)(\mu_2 - \mu_1)^T$$

クラス内分散の和

$$\mathbf{a}^T \mathbf{S}_W^\phi \mathbf{a}$$

$$(K_l)_{ij} = k(X_i, X_j), \quad (i \in C_l, j = 1, \dots, N)$$

$$Q_N = I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^T$$

$$\mathbf{S}_W^\phi = K_1^T Q_N K_1 + K_2^T Q_N K_2$$

※実際はカーネル法の表現能力の高さから、  
クラス内分散の和が0になるような解が選ばれてしまう(過学習)



正則化項を加える

$$\tilde{J}(\mathbf{a}) = \frac{\mathbf{a}^T \mathbf{S}_B^\phi \mathbf{a}}{\mathbf{a}^T (\mathbf{S}_W^\phi + \lambda \mathbf{I}_N) \mathbf{a}}$$

# 目次

6.1 双対表現

**6.2 カーネル関数の構成**

6.3 RBFネットワーク

6.4 ガウス過程

カーネル法では、特徴変換を考えなくとも  
カーネル関数を与えさえすればよい

この節では、具体的なカーネル関数の  
設計法について見ていく



カーネル関数は何か特徴ベクトルの内積  
という形になっていなければならない

$$\langle \Phi(X_i), \Phi(X_j) \rangle = k(X_i, X_j)$$

これを満たす必要十分条件は、  
カーネル関数が正定値性カーネル  
(グラム行列が半正定値行列)であるということ

# 補足

正定値カーネル

再生核ヒルベルト空間

リプレゼンター定理

## 正定値カーネルの定義

集合 $\mathcal{X}$ に対して、次の二つの条件を満たすカーネルを $\mathcal{X}$ 上の正定値カーネルという

対称性  $\forall x, y \in \mathcal{X}$  に対して  $k(x, y) = k(y, x)$

正値性  $\forall n \in \mathbb{N}, x_1, \dots, x_n \in \mathcal{X}, c_1, \dots, c_n \in \mathbb{R}$  に対し

$$\sum_{i,j} c_i c_j k(x_i, x_j) \geq 0$$

※これらはグラム行列が半正定値であることと同値

$$K_{ij} = k(x_i, x_j) \text{ を行列要素に持つ行列}$$

# 再生核ヒルベルト空間

集合 $\mathcal{X}$ 上の再生核ヒルベルト空間とは、  
 $\mathcal{X}$ 上の関数からなるヒルベルト空間 $\mathcal{H}$ で、  
任意の  $x \in \mathcal{X}$  に対して  $k(\cdot, x) \in \mathcal{H}$  が存在し

再生性

$$\langle f, k(\cdot, x) \rangle = f(x)$$

を満たすものをいう

このカーネル関数  $k$  を  $\mathcal{H}$  の再生核と呼ぶ

$\mathcal{X}$ 上の再生核ヒルベルト空間の再生核  $k$  は  
 $\mathcal{X}$ 上の正定値カーネルで、一意的

証明:

$$\begin{aligned}\sum_{i,j} c_i c_j k(x_i, x_j) &= \sum_{i,j} c_i c_j \langle k(\cdot, x_i) k(\cdot, x_j) \rangle \\ &= \langle \sum_i c_i k(\cdot, x_i), \sum_j c_j k(\cdot, x_j) \rangle \geq 0\end{aligned}$$

対称性、一意性はスライドでは割愛

※証明はしませんが、逆に正定値カーネルから  
再生核ヒルベルト空間を構成可能

特徴写像を  $\phi(\mathbf{x}) = k(\mathbf{x}, \cdot)$  と定めれば、再生性から

$$\begin{aligned}\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle &= \langle k(\mathbf{x}_i, \cdot), k(\mathbf{x}_j, \cdot) \rangle \\ &= k(\mathbf{x}_i, \mathbf{x}_j)\end{aligned}$$

以上から、正定値カーネルが特徴ベクトルの内積として与えられるカーネル関数に相当することが確認できた

# リプレゼンター定理

## 正則化付きの誤差関数

$$R(f) = R_L(\{f(\mathbf{x}_i), y_i\}_{i=1, \dots, N}) + \lambda R_P(\|f\|_{\mathcal{H}}^2)$$

ただし  $f$  : 再生核ヒルベルト空間  $\mathcal{H}$  の元

$R_L$  : 任意の関数

$R_P$  : 狭義単調増加関数

$\lambda > 0$  とする

このとき、最適解はカーネル関数の線形結合

$$f(\mathbf{x}) = \sum_{n=1}^N a_n k(\mathbf{x}_n, \mathbf{x}) \quad \text{でかける}$$

## 証明

再生核ヒルベルト空間 $\mathcal{H}$ に対して、  
データの張る部分空間  $\{k(\mathbf{x}_i, \cdot), i = 1, \dots, N\}$  を  
 $\mathcal{H}_0$ とし、その直交補空間を $\mathcal{H}_\perp$ とする

ここで、 $R_L$ の最適解を $f$ とすると、  
それぞれの成分  $f_0, f_\perp$  で

$$f = f_0 + f_\perp$$

と表せる

$$\begin{aligned}\langle f, k(\mathbf{x}_i, \cdot) \rangle &= \langle f_0, k(\mathbf{x}_i, \cdot) \rangle + \underbrace{\langle f_\perp, k(\mathbf{x}_i, \cdot) \rangle}_{= 0} \\ &= \langle f_0, k(\mathbf{x}_i, \cdot) \rangle\end{aligned}$$

つまり、 $f = f_0$  としてよい



また、正則化項  $R_P$  に関しても

$$\begin{aligned} R_P(\|f\|^2) &= R_P(\|f_0\|^2 + \|f_\perp\|^2) \\ &\geq R_P(\|f_0\|^2) \end{aligned}$$

より最適解は  $f = f_0$

$f_0$  は  $\mathcal{H}_0$  の元であったので  $R(f)$  の最適解は

$$f(\mathbf{x}) = \sum_{n=1}^N a_n k(\mathbf{x}_n, \mathbf{x})$$

と表せる(証明終)

リプレゼンター定理から、データを高次元の特徴空間に写像したとしても、その解はデータ数のオーダーの線形和で与えられることが保証される！

$$f(\mathbf{x}) = \sum_{n=1}^N a_n k(\mathbf{x}_n, \mathbf{x})$$

※制約条件に対するリプレゼンター定理もほぼ同じ様にして証明

**PRMLに戻ります**

**(6.13)～(6.22)が  
正定値カーネルになることを確認(板書にて)**

# 代表的なカーネル関数

## 多項式カーネル

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + c)^M \quad (c > 0, M \in \mathbb{N})$$

## ガウスカーネル

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2 / 2\sigma^2)$$

※ガウスカーネルは無限次元の特徴ベクトルに対応する(演習6.11)

カーネル法は入力空間  $\mathcal{X}$  が実数のみならず、  
文字列、グラフ構造、集合といった場合にも  
カーネル関数さえ定義できれば適用可能

→例：演習6.12にて紹介

生成モデルを用いてカーネルを定義することも可能

$$k(\mathbf{x}, \mathbf{x}') = p(\mathbf{x})p(\mathbf{x}')$$

カーネル関数の構成法から、上のカーネルは  
(6.29)～(6.31)のように拡張可能

他にも、フィッシャーカーネル(6.33)などもある

# 目次

6.1 双対表現


6.2 カーネル関数の構成

**6.3 RBFネットワーク**

6.4 ガウス過程




**3章では、固定された基底関数の  
線形結合を用いた回帰を考えた**



- **RBF(radical basis function:動径基底関数)を  
基底関数に用いることが多い**
- **ということで、RBFに着目してみていく**

RBFは、関数補間で初めて導入された



$$f(\mathbf{x}) = \sum_n w_n h(\|\mathbf{x} - \mathbf{x}_n\|)$$

最小二乗法で求解

→応用上、過学習を抑える必要(正則化)

**※正則化項に微分値を用いた二乗和誤差関数では、最適解はグリーン関数の線形和で表される**

入力変数にノイズが含まれる場合にもRBFは利用される

入力  $\mathbf{x}$  のノイズを  $\xi$  とすると、二乗和誤差関数は

分布  $\nu(\xi)$  に従う確率変数

$$E = \frac{1}{2} \sum_{n=1}^N \int \{y(\mathbf{x}_n + \xi) - t_n\}^2 \nu(\xi) d\xi \quad (6.39)$$

変分法によって最適な  $y(\mathbf{x})$  は

$$y(\mathbf{x}) = \sum_{n=1}^N t_n h(\mathbf{x} - \mathbf{x}_n) \quad \text{RBF} \quad (6.40)$$

となる


ここでのRBFは

$$h(\mathbf{x} - \mathbf{x}_n) = \frac{\nu(\mathbf{x} - \mathbf{x}_n)}{\sum_{n=1}^N \nu(\mathbf{x} - \mathbf{x}_n)} \quad (6.41)$$


で与えられ、全てのデータ点を  
基底として持ったモデルとなっている

→Nadaraya-Watsonモデル(後述)

**(6.41)は正規化されているため、  
基底によって入力空間を埋め尽くすことができる**




正規化なし



正規化あり

**RBFでは基底の計算量がデータ数に相当するため、  
データが多いときは予測にかかる計算コストが大きい**



- ・直交最小二乗法
  - ・クラスタリングアルゴリズム
- 等を用いた基底に用いるデータ点の選別**

# Nadaraya-Watsonモデル(カーネル回帰)

(6.41)をカーネル密度推定から再導出する

テストデータセット  $\{\mathbf{x}_n, t_n\}_{n=1}^N$

Parzen推定法を用いて、同時分布  $p(\mathbf{x}, t)$  を推定することを考える

$$p(\mathbf{x}, t) = \frac{1}{N} \sum_{n=1}^N f(\mathbf{x} - \mathbf{x}_n, t - t_n) \quad (6.42)$$

密度関数



1.5.5節で議論したように、回帰関数  $y(\mathbf{x})$  を求めるには  $E[t|\mathbf{x}]$  を考えればよい。このとき、(6.42)を用いて

$$E[t|\mathbf{x}] = \frac{\sum_n \int t f(\mathbf{x} - \mathbf{x}_n, t - t_n) dt}{\sum_m \int f(\mathbf{x} - \mathbf{x}_m, t - t_m) dt} \quad (6.43)$$

ここで、 $f(\mathbf{x}, t)$  の  $t$  についての平均を0とすると

————— Nadaraya-Watsonモデル —————

$$\begin{aligned} y(\mathbf{x}) &= \frac{\sum_n g(\mathbf{x} - \mathbf{x}_n) t_n}{\sum_m g(\mathbf{x} - \mathbf{x}_m)} \\ &= \sum_n k(\mathbf{x}, \mathbf{x}_n) t_n \end{aligned} \quad (6.45)$$

$k(\mathbf{x}, \mathbf{x}_n), g(\mathbf{x})$  は(6.46),(6.47)で与えられる

